

UNIAGRARIA

Fundación Universitaria Agraria de Colombia

LA **U VERDE** DE COLOMBIA

Institución Universitaria Personería Jurídica Nº 2599-86 M.E.N.

Institución de Educación Superior sujeta a inspección y vigilancia por parte del M.E.N.

Bogotá
Calle 170 Nº 54A - 10
Línea de atención
PBX: 667 1515

Facatativá
Carrera 2 Nº 4 - 21
Líneas de atención
890 07 37 - 890 07 32

www.**uniagraria**.edu.co

informes@uniagraria.edu.co

UNIAGRARIA

De los Datos a la Transformación

La física de la Inteligencia Artificial al servicio de la ciencia, las organizaciones y la sociedad

Carlos Andrés Gómez Vasco
Conferencista · XI Simposio Uniagrarista

Contenido

1. Los datos como motor de la ciencia
2. Nobel de Física 2024
3. De la materia a los algoritmos
4. Paisajes de energía: Hopfield, Boltzmann y retropropagación
5. La nueva frontera: PINNs, IAIFI y computación cuántica



Los datos

Motor de la ciencia actual



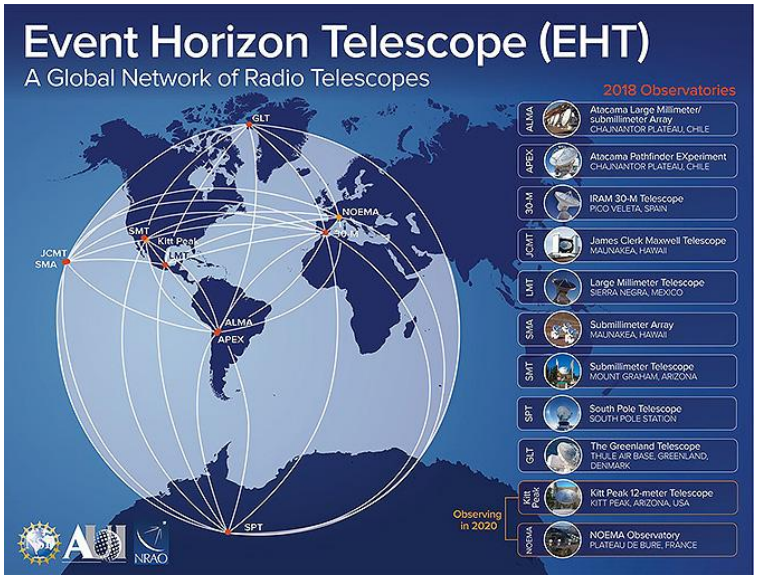
XI SIMPOSIO UNIAGRARISTA

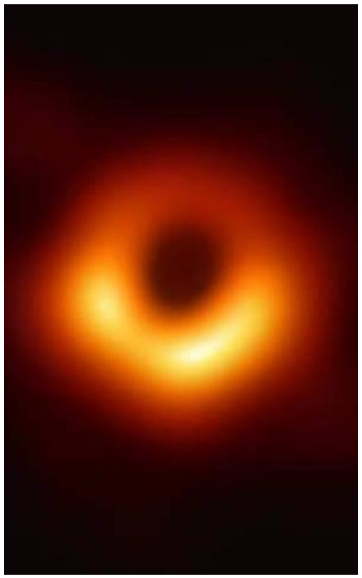
Medio Natural y Experiencias de Investigación Formativa

Datos e inteligencia artificial: Transformando la ciencia, las organizaciones y la sociedad

350 terabytes diarios por telescopio

Event Horizon Telescope (EHT), abril de 2017





350 TB

diarios por telescopio

8

radiotelescopios apuntando a la galaxia M87



Durante diez días de abril, la red de telescopios reunió datos que se transportaron en discos duros. Reconstruir la primera imagen de un agujero negro exigió algoritmos de procesamiento masivo de datos; Katie Bouman fue figura clave de ese trabajo.

La IA ya transforma la sociedad

De la ciencia de frontera a la vida cotidiana



Gemini | Claude

ChatGPT | deepseek

¿Por qué, entonces, el Nobel de 2024 fue de Física?

Ciencia: descubrimientos acelerados en astronomía, clima, materiales y salud.

Organizaciones: decisiones basadas en datos, automatización y asistentes.

Sociedad: asistentes conversacionales y contenido generado al alcance de todos.



UNIAGRARIA

Nobel de Física 2024

La física detrás de la IA



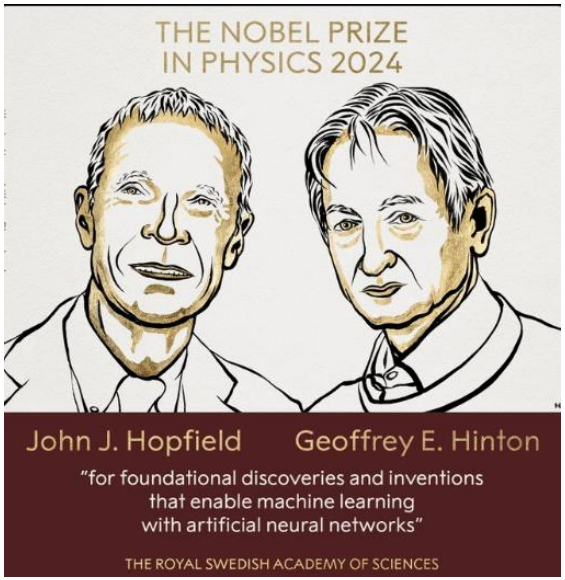
XI SIMPOSIO UNIAGRARISTA

Medio Natural y Experiencias de Investigación Formativa

Datos e inteligencia artificial: Transformando la ciencia, las organizaciones y la sociedad

Premio Nobel de Física 2024

John J. Hopfield y Geoffrey E. Hinton



Física estadística

↓

Aprendizaje automático

"Por descubrimientos e invenciones fundamentales que permiten el aprendizaje automático con redes neuronales artificiales."

Las redes neuronales no son solo "ingeniería de software": funcionan gracias a la física estadística y la mecánica de sistemas.

Por eso el premio fue de Física.



De la materia a los algoritmos

Un siglo de ideas



XI SIMPOSIO UNIAGRARISTA

Medio Natural y Experiencias de Investigación Formativa

Datos e inteligencia artificial: Transformando la ciencia, las organizaciones y la sociedad

Un siglo de ideas

Hitos que conectan la física con el aprendizaje automático

1925 Modelo de Ising: spins que interactúan con sus vecinos

1943 Neurona lógica de McCulloch y Pitts

1957 Perceptrón de Rosenblatt: la neurona que aprende

1982 Redes de Hopfield: memoria como paisaje de energía

1985 Máquina de Boltzmann (Ackley, Hinton y Sejnowski)

1986 Retropropagación en Nature (Rumelhart, Hinton y Williams)

2019 PINNs: redes neuronales informadas por la física

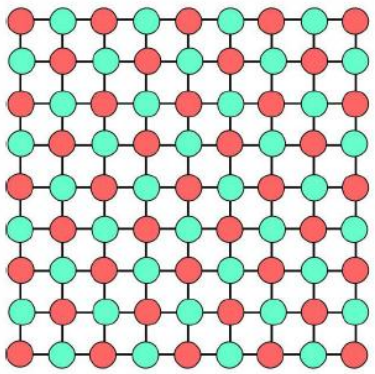
2020 Nace el instituto IAIFI (NSF / MIT)

2024 **Nobel de Física para Hopfield y Hinton**

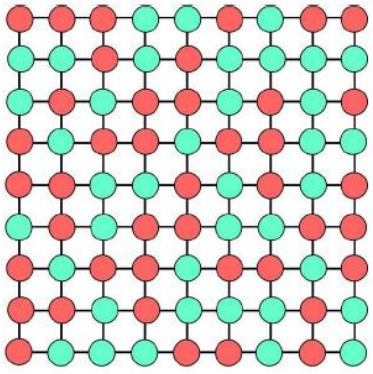


Modelo de Ising (1925)

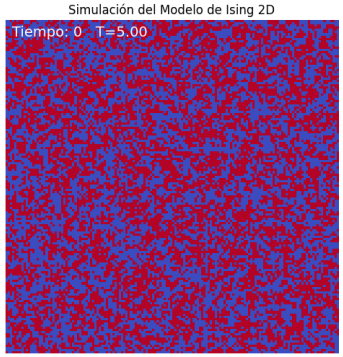
Ernst Ising y Wilhelm Lenz: imanes que "conversan" con sus vecinos



$T = 0$

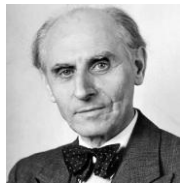


$T > T_c$





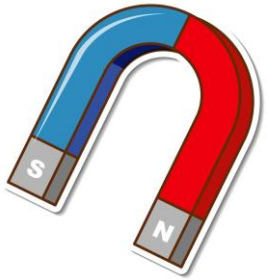
E. Ising



W. Lenz

$$E = -J \sum s_i s_j$$

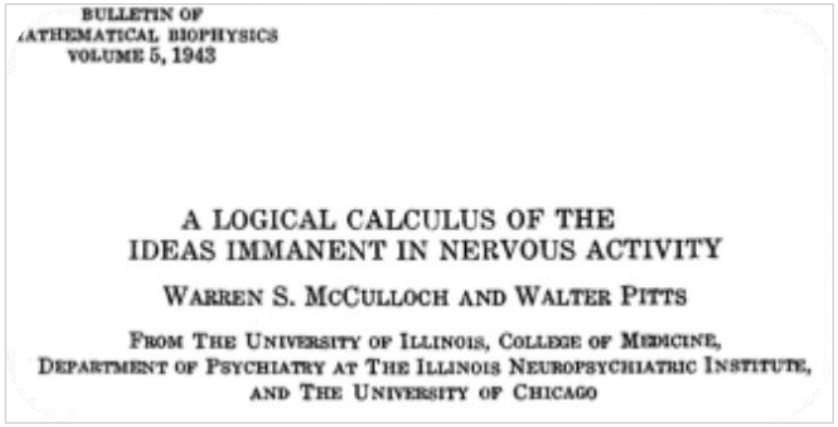
1. Cada spin busca alinearse con sus vecinos.
2. Energía baja = orden; energía alta = conflicto.
3. El sistema evoluciona reduciendo su energía.
4. La temperatura añade ruido: alta T, desorden; baja T, orden.



Al enfriarse se forman dominios magnéticos

La neurona lógica (1943)

Warren McCulloch y Walter Pitts: ¿puede el cerebro calcular?



BULLETIN OF
MATHEMATICAL BIOPHYSICS
VOLUME 5, 1943

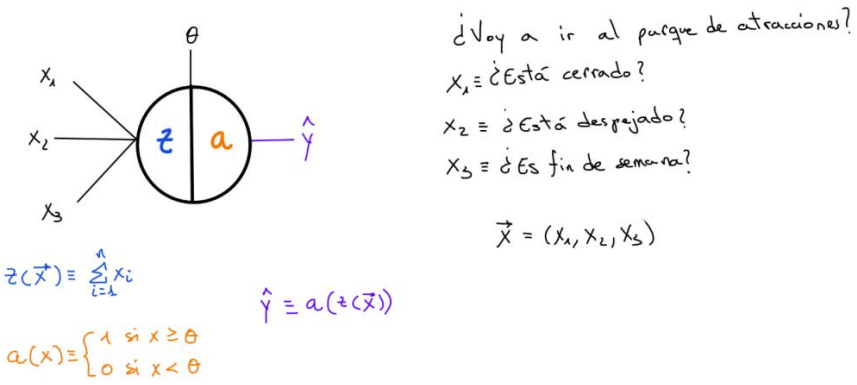
A LOGICAL CALCULUS OF THE
IDEAS IMMANENT IN NERVOUS ACTIVITY

WARREN S. MCCULLOCH AND WALTER PITTS

FROM THE UNIVERSITY OF ILLINOIS, COLLEGE OF MEDICINE,
DEPARTMENT OF PSYCHIATRY AT THE ILLINOIS NEUROPSYCHIATRIC INSTITUTE,
AND THE UNIVERSITY OF CHICAGO

El artículo combinó:

- Neurofisiología (McCulloch)
- Lógica matemática (Pitts)
- El deseo de expresar el pensamiento de forma formal



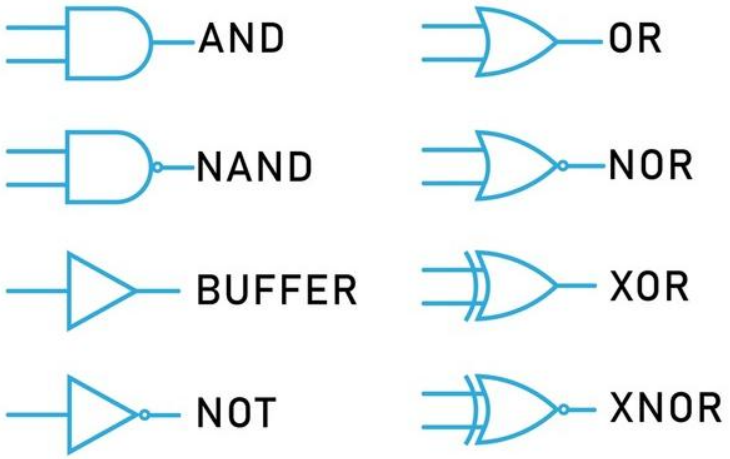
Neurona = suma de entradas + umbral: se activa (1) o no (0).

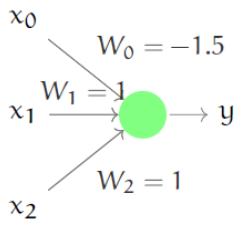
Su meta no era crear IA, sino entender cómo calcula el cerebro.



Neuronas como compuertas lógicas

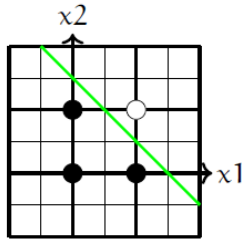
Redes de neuronas binarias pueden implementar funciones lógicas





$$\text{Salida} = g(-1.5 + x_1 + x_2)$$

x_1	x_2	z	h_{umbral}
0	0	-1.5	0
0	1	-0.5	0
1	0	-0.5	0
1	1	0.5	1



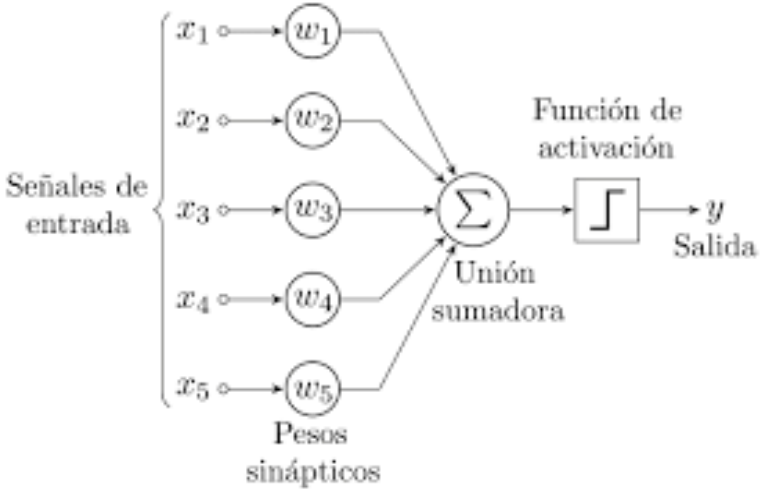
$$\text{Salida} = g(-15 + 10x_1 + 10x_2)$$

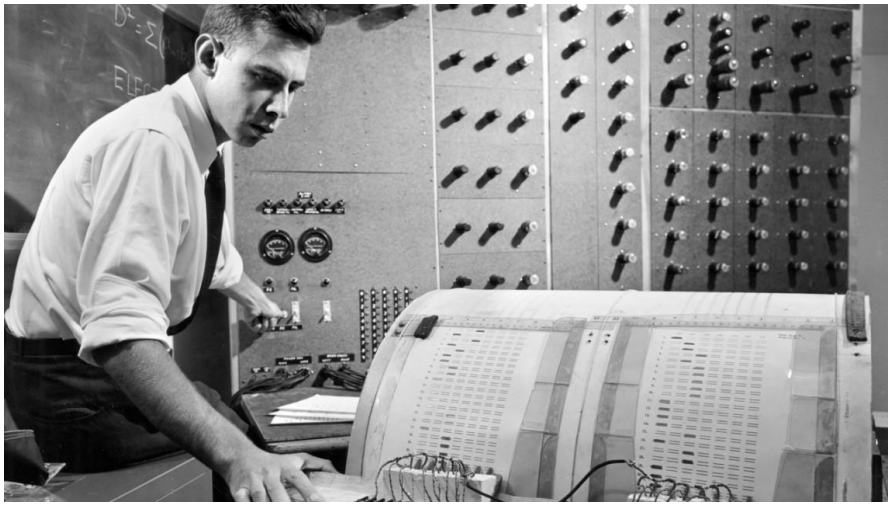
x_1	x_2	z	$h_{sigmoide}$
0	0	-15	0.0000003
0	1	-5	0.0067
1	0	-5	0.0067
1	1	5	0.993

- El artículo de Turing (1936) ya circulaba entre lógicos y matemáticos.
- Pitts había estudiado a Russell, Whitehead, Kleene, Church y Hilbert: el mismo círculo de Turing.
- Es casi seguro que conocía la computabilidad universal antes de 1943.

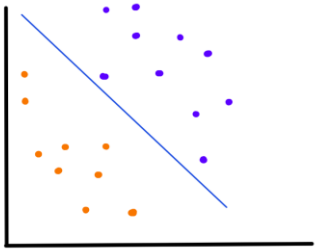
Perceptrón de Rosenblatt (1957)

La primera neurona artificial que aprende de los datos





- **Entrada:** matriz de 20 × 20 fotoceldas
- **Pesos:** potenciómetros
- **Aprendizaje:** motores eléctricos ajustaban los pesos



Límite: solo separa clases con una línea recta (problema XOR).

Paisajes de energía

Hopfield, Boltzmann y Hinton



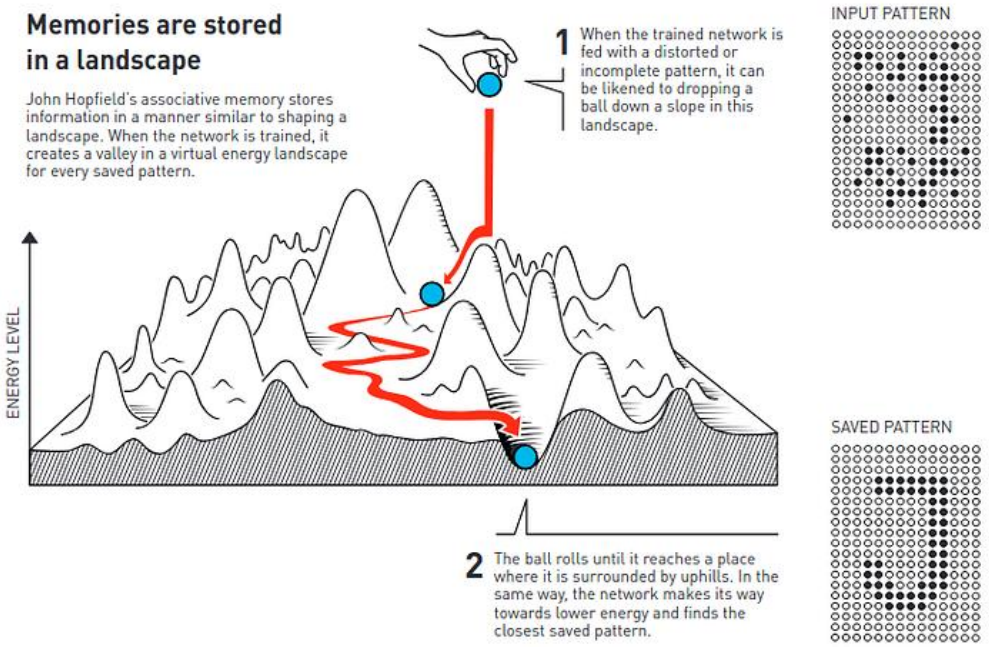
XI SIMPOSIO UNIAGRARISTA

Medio Natural y Experiencias de Investigación Formativa

Datos e inteligencia artificial: Transformando la ciencia, las organizaciones y la sociedad

Redes de Hopfield (1982)

La memoria como un paisaje de energía



$$E = -\tfrac{1}{2} \Sigma w_{ij} s_i s_j$$

Cada recuerdo es un valle: un mínimo de energía.

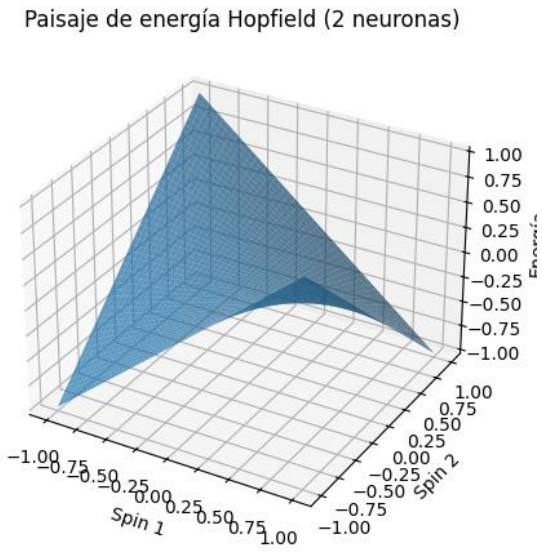
Ante un patrón incompleto, la red "rueda" cuesta abajo hasta el recuerdo más cercano: memoria asociativa.

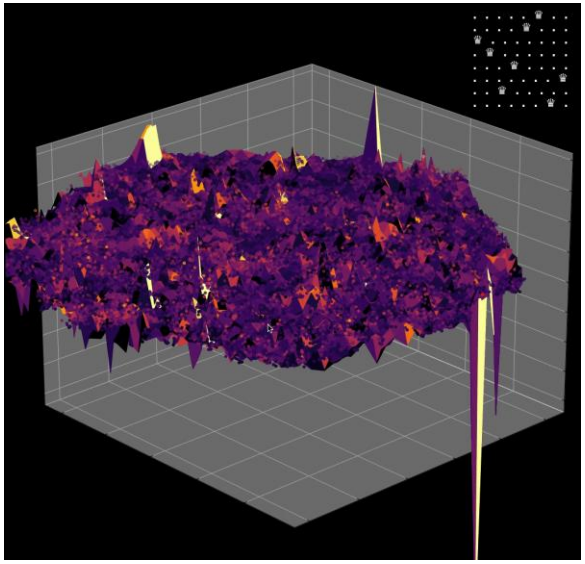
Aprender (regla de Hebb): neuronas que se activan juntas refuerzan su conexión w_{ij}.

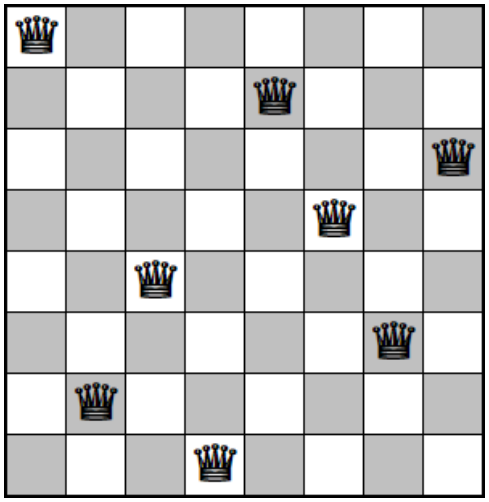
Simulación interactiva: visualize-it.github.io/hopfield_networks

Hopfield: la madre de las redes neuronales

Potencia conceptual y límites prácticos







Optimización: N reinas

N(N−1)/2
pesos: todas las neuronas conectadas

~10¹²
pesos con un millón de neuronas

0,14 N
recuerdos como máximo

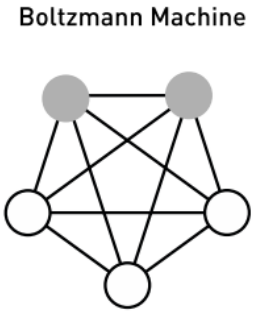
Mínimos espurios
falsos recuerdos y estancamiento

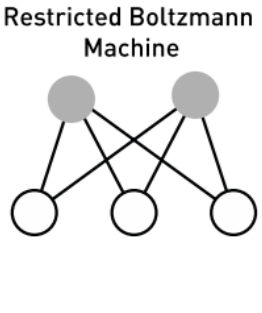
Máquina de Boltzmann (1985)

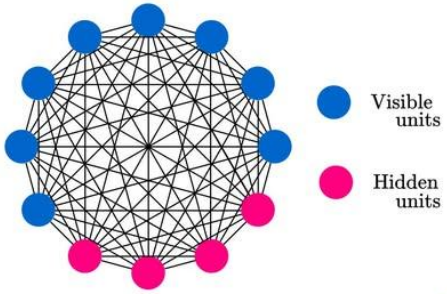
Hinton añade azar y temperatura para aprender distribuciones



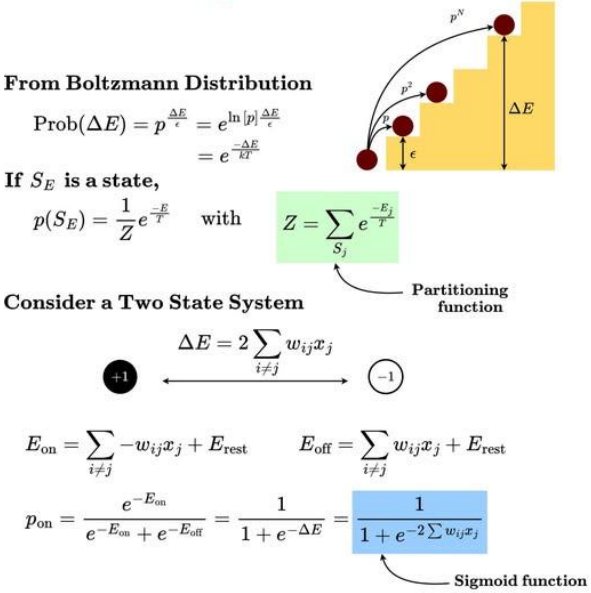
Geoffrey Hinton





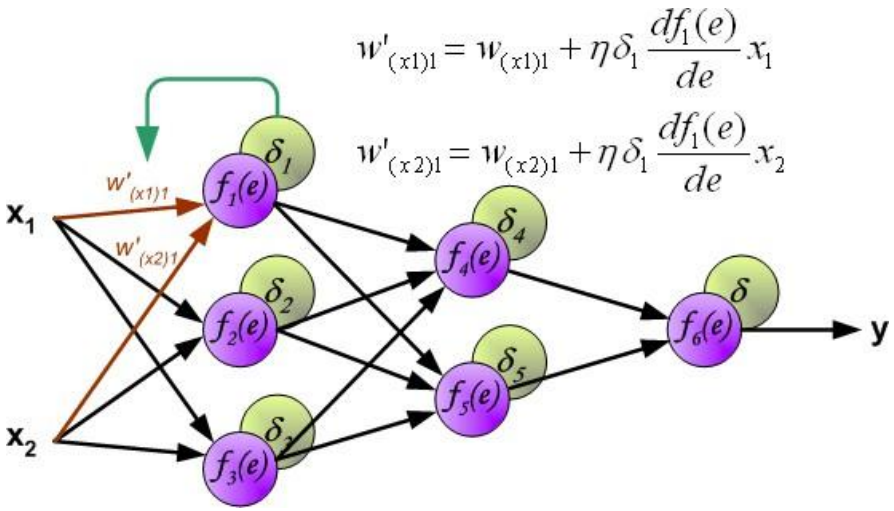


- **Unidades estocásticas:** se activan con cierta probabilidad.
- **Distribución de Boltzmann:** $P(s) \propto e^{-E(s)/T}$.
- **Unidades ocultas** que capturan la estructura de los datos.
- **La temperatura** ayuda a escapar de mínimos locales.



Retropropagación (1986)

Rumelhart, Hinton y Williams: aprender ajustando millones de pesos



letters to nature

Nature **323**, 533 - 536 (09 October 1986); doi:10.1038/323533a0

Learning representations by back-propagating errors

David E. Rumelhart*, Geoffrey E. Hinton† & Ronald J. Williams*

* Institute for Cognitive Science, C-015, University of California, San Diego, La Jolla, California 92093, USA
† Department of Computer Science, Carnegie-Mellon University, Pittsburgh, Philadelphia 15213, USA

El error en la salida se propaga hacia atrás, capa por capa, para calcular cuánto contribuyó cada peso.

Con esos gradientes, el descenso por gradiente ajusta toda la red.

$$w \leftarrow w - \eta \, \partial L / \partial w$$

η: tasa de aprendizaje

¿Cómo aprende una red neuronal?

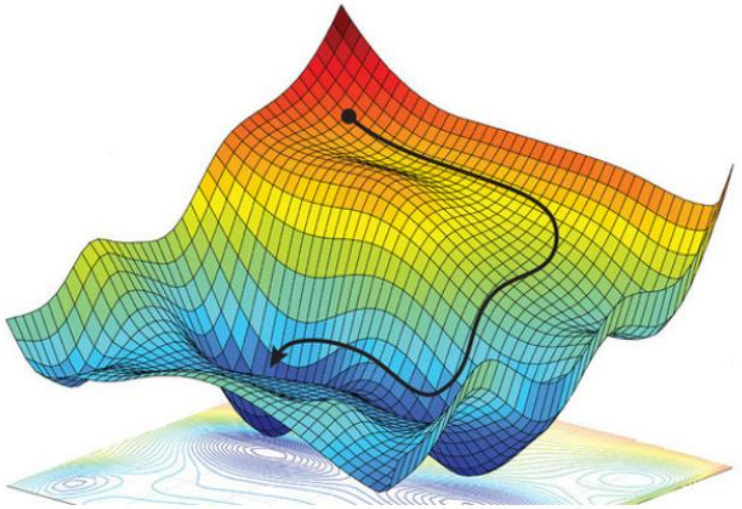
Descender por el paisaje de la pérdida

1. **Forward**
   Los datos atraviesan la red y producen una predicción ŷ.

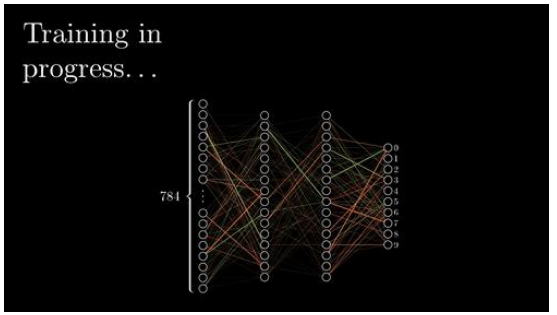
2. **Pérdida**
   L(y, ŷ) mide el error; por ejemplo, el error cuadrático medio.

3. **Backward**
   El error se propaga hacia atrás y se calculan los gradientes.

4. **Actualización**
   Se ajustan los pesos. Una pasada por todos los datos es una época.



Paisaje de pérdida: aprender es bajar al valle



La nueva frontera

Física e IA se cruzan de nuevo



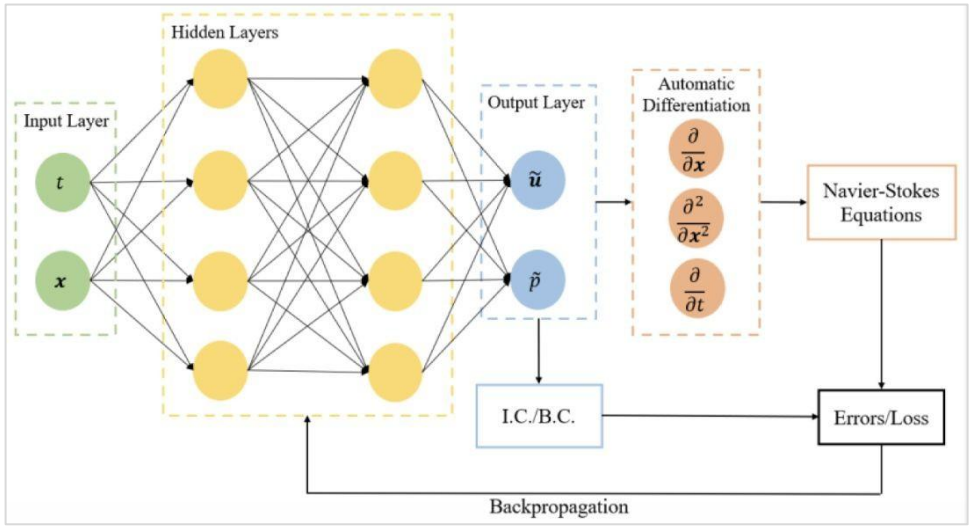
XI SIMPOSIO UNIAGRARISTA

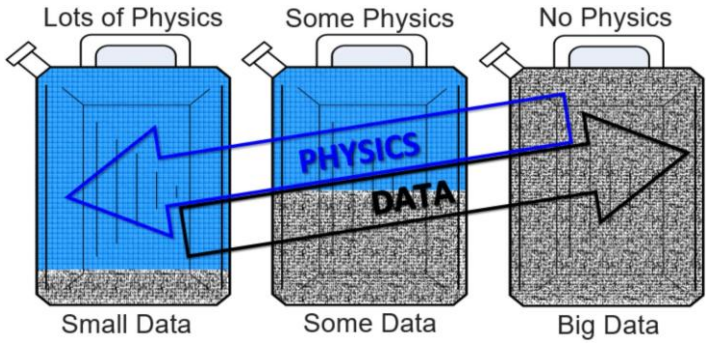
Medio Natural y Experiencias de Investigación Formativa

Datos e inteligencia artificial: Transformando la ciencia, las organizaciones y la sociedad

Redes neuronales informadas por la física

PINNs: datos y leyes físicas en una misma función de pérdida





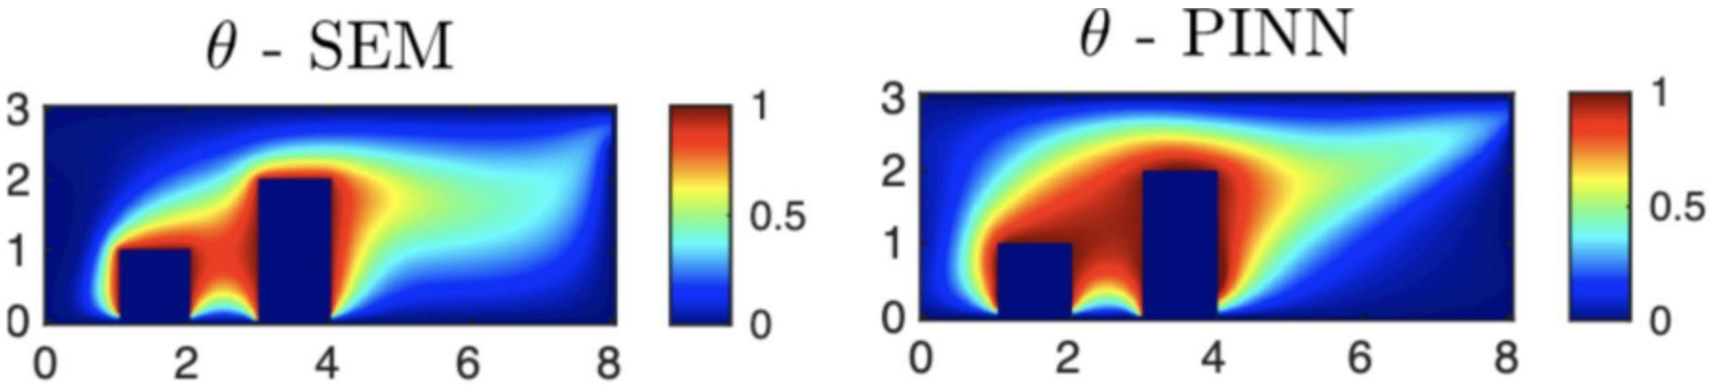
$$\frac{D\mathbf{u}}{Dt} = \frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u}\cdot\nabla)\mathbf{u} = \nu\nabla^2\mathbf{u} - \frac{1}{\rho}\nabla p + \frac{1}{\rho}\mathbf{f}$$

$$L_{total} = L_{datos} + L_{EDP} + L_{CF} + L_{CI}$$

La red debe ajustar los datos y, a la vez, cumplir las ecuaciones diferenciales (como Navier–Stokes) y las condiciones de frontera e iniciales. Así aprende bien con pocos datos.

Mecánica de fluidos oculta

Raissi, Yazdani y Karniadakis, Science 367 (2020)



Concentración θ: simulación numérica (SEM) frente a la reconstrucción con una PINN

A partir solo de imágenes de un trazador (como humo o tinte), la PINN infiere campos de velocidad y presión que nunca se midieron directamente.

En las organizaciones

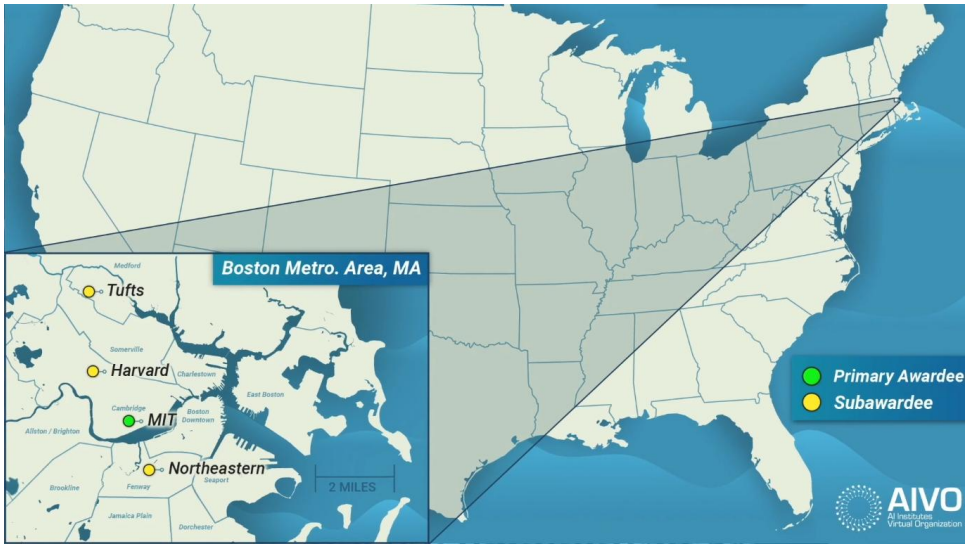
- Hidrología y riego
- Clima y suelos para el agro
- Energía e ingeniería

IAIFI: IA y física fundamental

Instituto de la NSF con sede en el MIT, creado en 2020

The NSF Institute for Artificial Intelligence and Fundamental Interactions

Uno de los institutos inaugurales de IA de la National Science Foundation de EE. UU., anclado en el Laboratorio de Ciencia Nuclear del MIT.



Aprendizaje profundo + pensamiento profundo = comprensión más profunda

Descubrimientos en física

IA que incorpora principios físicos para los problemas más difíciles.

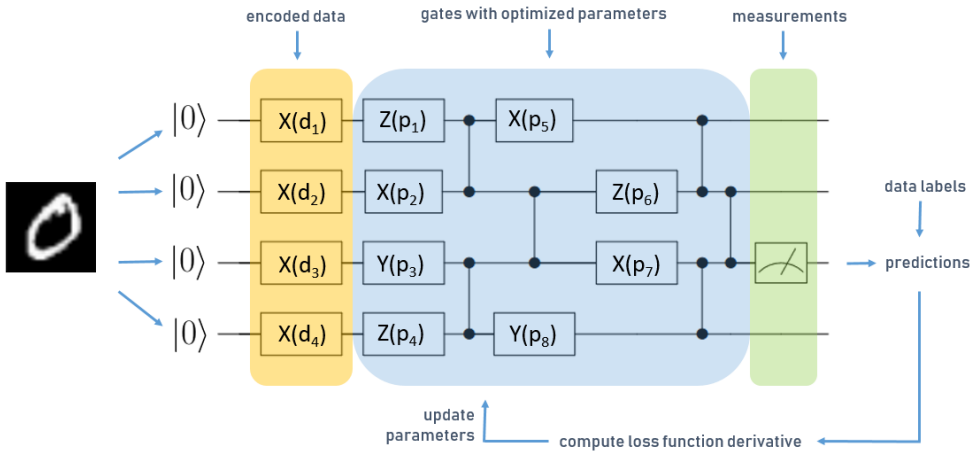
IA fundacional

Principios físicos para una IA más robusta, confiable y transparente.



Computación cuántica e IA

Una perspectiva hacia el futuro



Red neuronal cuántica: circuito parametrizado

Quantum Boltzmann Machine

Mohammad H. Amin,[1,2] Evgeny Andriyash,[1] Jason Rolfe,[1] Bohdan Kulchytskyy,[3] and Roger Melko[3,4]
[1]*D-Wave Systems Inc., 3033 Beta Avenue, Burnaby BC Canada V5G 4M9*
[2]*Department of Physics, Simon Fraser University, Burnaby, BC Canada V5A 1S6*
[3]*Department of Physics and Astronomy, University of Waterloo, 200 University Avenue West Waterloo, Ontario, Canada N2L 3G1*
[4]*Perimeter Institute for Theoretical Physics, Waterloo, Ontario, N2L 2Y5, Canada*

Inspired by the success of Boltzmann Machines based on classical Boltzmann distribution, we propose a new machine learning approach based on quantum Boltzmann distribution of a transverse-field Ising Hamiltonian. Due to the non-commutative nature of quantum mechanics, the training process of the Quantum Boltzmann Machine (QBM) can become nontrivial. We circumvent the problem by introducing bounds on the quantum probabilities. This allows us to train the QBM efficiently by sampling. We show examples of QBM training with and without the bound, using exact diagonalization, and compare the results with classical Boltzmann training. We also discuss the possibility of using quantum annealing processors like D-Wave for QBM training and application.

El viejo modelo de energía de Boltzmann, ahora con estados cuánticos.

Máquinas de Boltzmann cuánticas

Amin et al., Physical Review X (2018).

Redes cuánticas

Circuitos que se entrenan como una red neuronal.

Retos

Ruido, escala del hardware y ventaja aún por demostrar.



De los datos a la transformación

Lo que la física de la IA significa para nosotros

Ciencia

Modelos que combinan leyes físicas y datos aceleran el descubrimiento.

Organizaciones

Del agro a la industria: buenas decisiones aun con pocos datos, cuando la física completa lo que falta.

Sociedad

Entender los fundamentos permite usar la IA con criterio, ética y sentido crítico.

La IA no es magia: es física, matemáticas y datos al servicio de las personas.



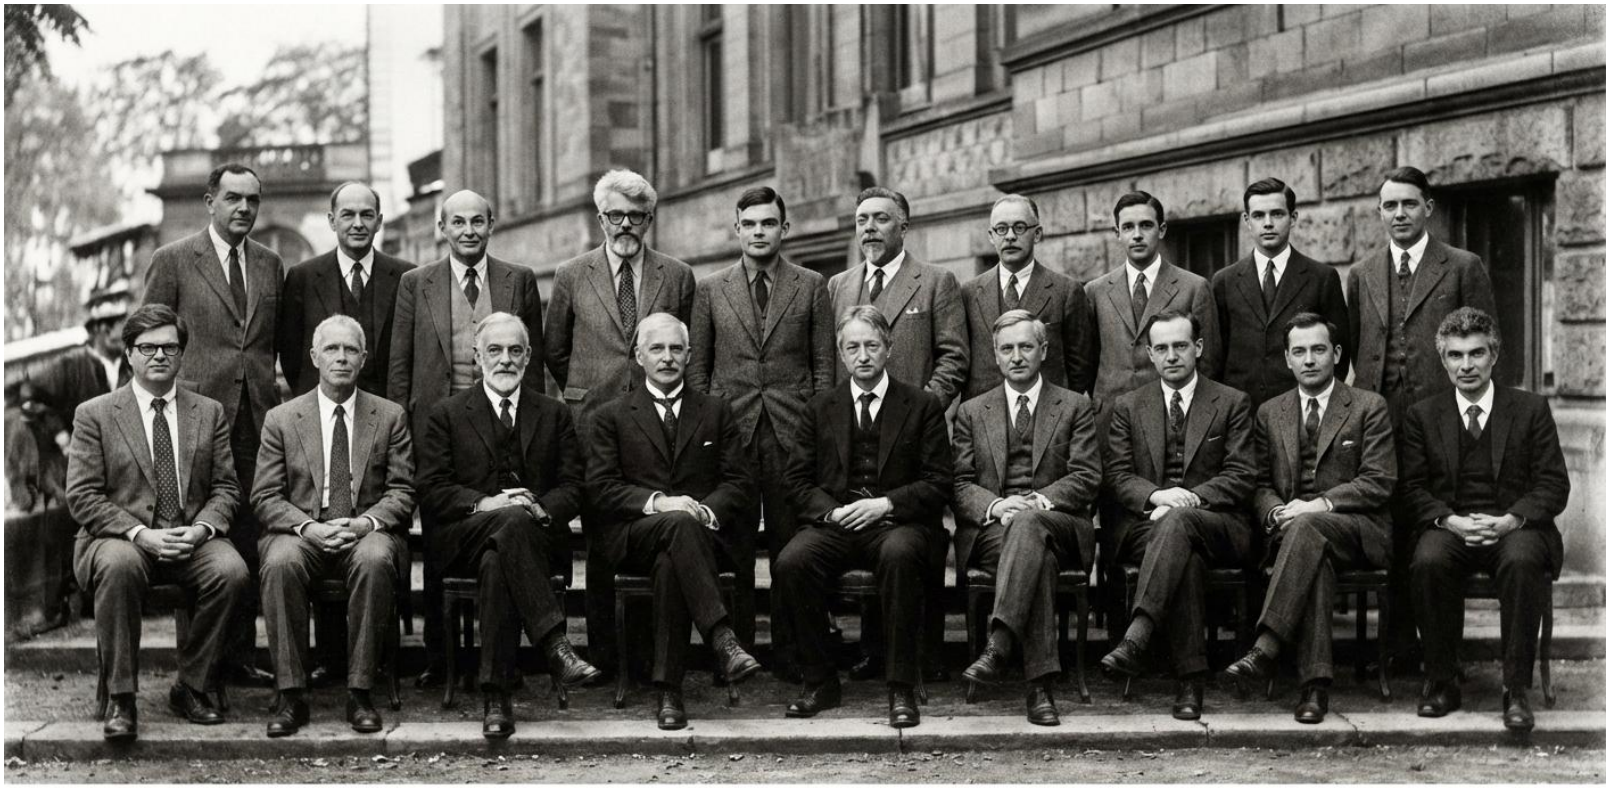
XI SIMPOSIO UNIAGRARISTA

Medio Natural y Experiencias de Investigación Formativa

Datos e inteligencia artificial: Transformando la ciencia, las organizaciones y la sociedad

Una historia colectiva

Física, matemáticas, neurociencia y computación



1. Y. LeCun, 2. J. Hopfield, 3. E. Ising, 4. G. Hinton, 5. R. Neal, 6. Y. Bengio, 7. H. Simon, 8. M. Minsky, 9. J. McCarthy, 10. A. Turing, 11. N. Wiener, 12. W. McCulloch, 13. W. Pitts, 14. F. Rosenblatt, 15. A. Samuel.



GRACIAS

¿Preguntas?